

Grounded: Klimaat, Bodem en Data: werken met R

Ronald M. Visser

Marleen van Zon

2026-10-05

Table of contents

Voorwoord	4
1 Introductie	5
2 Werkcollege 1: de eerste stappen met R en Rstudio	6
2.1 Inleiding	6
2.2 Project aanmaken	6
2.3 Een eerste bestand aanmaken	7
2.4 Start van een script met analyses	7
2.5 Inlezen grondwater data	9
2.6 Verkennen van de data	12
2.7 Zelf aan de slag met een aantal opdrachten	14
2.8 De eerste grafieken	14
2.9 Zelf aan de slag met een aantal opdrachten	21
2.10 Op zoek naar aanvullende data	21
2.11 Zelf aan de slag met een aantal opdrachten	23
2.12 Combineren van datasets	24
2.13 Zelf aan de slag met een aantal opdrachten	25
2.14 Huiswerk: verwerken in de eigen projecten	25
3 Werkcollege 2: werken met weer- en klimaatdata	26
3.1 Inleiding	26
3.2 Weerdata	26
3.2.1 Project en script aanmaken	26
3.2.2 Data inlezen en de eerste verkenning van de data	27
3.3 Grafieken maken voor de neerslag per dag	30
3.3.1 Weer zelf aan de slag	34
3.4 Temperatuur	34
3.4.1 Nu even zelf nadenken	38
3.4.2 Zelf aan de slag	40
3.5 Grafieken combineren	40
3.5.1 Zelf aan de slag	41
3.6 Klimaat: meerjarige data	43
3.6.1 Zelf doen:	43
3.6.2 En dan weer zelf aan de slag	45

3.7	Historische klimaatdata toevoegen	45
3.7.1	En nu zelf weer aan de slag.	48
3.8	Project	48
References		50

Voorwoord

Dit is een boek gemaakt middels Quarto (<https://quarto.org/docs/books/>). Het is gemaakt in het kader van de Saxion minor Grounded: klimaat, bodem en data (<https://www.saxion.nl/opleidingen/minoren/g/grounded-klimaat-bodem-en-data>) van Saxion. Deze minor wordt vormgegeven samen met de onderzoeksgroep GROUNDED (Ground Expertise by data: <https://groundexpertisebydata.nl>), waardoor we de koppeling onderzoek en onderwijs versterken. Daarnaast is dit ook een product van het door Comenius gefinancierde project Kades als Duurzaam Erfgoed (KADE; <https://doi.org/10.61686/CAOBG60422>).

1 Introductie

Dit [quarto](#)-boek bevat een aantal oefeningen om te leren werken met [R](#). Het bestaat uit drie verschillende werkcolleges:

- College 1
- College 2
- College 3

Voordat je aan college 1 begint, moet je eerst zorgen dat je R geïnstalleerd hebt. Zorg dat je R eerst download vanaf <https://cran.r-project.org/>. Installeer dit daarna.

We maken in dit werkcollege gebruik van RStudio. Nadat je R geïnstalleerd hebt, download je RStudio vanaf <https://posit.co/downloads/> en installeer dit ook.

2 Werkcollege 1: de eerste stappen met R en Rstudio

2.1 Inleiding

We gaan eerst even leren werken in RStudio. Dit is een gratis en open-source geïntegreerde ontwikkelomgeving (IDE) voor R. Hierin is het belangrijk om met projecten te werken, omdat dit programmeren in R eenvoudiger en sneller maakt. Als je in een project werkt, wordt de werkdirectory automatisch ingesteld; iets wat je handmatig moet doen wanneer je R-scripts buiten projecten om schrijft. De eerste stap om aan een nieuw onderzoek te beginnen, is dus RStudio openen en vervolgens een nieuw project aan te maken.

2.2 Project aanmaken

Maak een nieuw project aan in een nieuwe map. Deze noemen we nu Grounded_WC1.

De stappen die je daarvoor moet zetten, staan heel goed uitgelegd op de website van de makers: <https://support.posit.co/hc/en-us/articles/200526207-Using-RStudio-Projects>. Volg die stappen dus voor deze opdracht.

Tip

Er zijn diverse instellingen in RStudio. Deze zijn te vinden via **Menu > Tools > Global Options...** Zorg dat je in ieder geval het automatisch opslaan van de workspace uitzet, omdat je dan iedere analyse met een verse omgeving begint. Dit voorkomt fouten.




Figure 2.1: Instellingen van RStudio

2.3 Een eerste bestand aanmaken

Het project bevat nog geen bestanden. Daarom maken we nu een eerste script aan. Dat kan via het menu middels **File > New File > R Script** (of druk op **CTRL + SHIFT + N**).

In het lege script moeten jullie nu de eerste regel code schrijven

```
print("Hello World!")
```

Dit is de regel waarmee vrijwel iedere programmeeroefening begint. Je kunt dit bestand nu opslaan door op de save-knop te drukken of via **CTRL + S** het op te slaan. Kies een logische bestandsnaam, bijvoorbeeld: “Grounded_WC1.R”

Je kunt dit script nu als geheel uitvoeren door **CTRL + SHIFT + S** te typen of op de “Source”-knop te klikken. Als het goed is, krijg je nu de output “Hello World!” in het Console-scherf. Dat is jouw eerste script!

2.4 Start van een script met analyses

De regel met `hello world` was maar een voorbeeld en die hebben we niet meer nodig. Verwijder dus de tekst. De gaan nu een script maken om een simpele analyse uit te voeren. Daartoe hebben we een aantal libraries nodig. Libraries, ook wel packages genoemd, zijn collecties met kant en klare functies en datasets.

💡 Tip

Ieder analyse-bestand begint altijd met het aanroepen van de benodigde bibliotheken en eventuele mappen die moeten worden aangemaakt. Hierdoor is de basis altijd goed terug te vinden. Soms kom je tijdens het schrijven van de analyses erachter dat een bepaalde library moet worden aangeroepen. Zorg dan dat die altijd bovenaan wordt ingevoegd.

Kopieer de onderstaande code naar jouw script uit de voorgaande opdracht.

```
# load libraries
library(dplyr)
library(ggplot2)
library(lubridate)

# force non scientific formatting of numbers
options(scipen = 999)
options(digits=3)
```

💡 Tip

Het hashtag symbool (#) gebruik je voor commentaren in de code. Dit wordt nooit uitgevoerd, maar vergroot de leesbaarheid van een script.

De kans is groot dat de eerste keer de libraries dplyr (Wickham, François, et al. 2023), ggplot (Wickham 2016) en lubridate (Grolemund and Wickham 2011) nog niet geïnstalleerd zijn. De installatie van packages staat uitgelegd op bijvoorbeeld deze locatie: <https://libguides.chapman.edu/R/packages>. Volg deze stappen indien nodig.

Naast het laden van libraries, stellen we ook de formatting van getallen in, door het aantal decimalen op 3 te zetten en getallen non-scientific te zetten.

We gaan nu eerst twee mappen aanmaken. De eerste **data** is voor het opslaan van de ruwe data. Daarnaast een map waarin we grafieken en dergelijke exporteren, die noemen we **export**.

```
# create folders
dir.create("data")
dir.create("export")
```

💡 Tip

Hierna zullen we niet meer zeggen dat je code moet kopiëren. We gaan ervan uit dat je dat doet. Code is herkenbaar aan het eigen **lettertype**.

2.5 Inlezen grondwater data

Ga nu naar de website <https://www.grondwatertools.nl/gwsinbeeld/>. Zoek op de kaart naar Deventer en zoek het grondwaterpunt “B27G0060”.




Figure 2.2: De website <https://www.grondwatertools.nl/gwsinbeeld/> met daarin het grondwaterpunt B27G0318.

Als je nu op de link met “Toon” erop klikt, krijg je het onderstaande beeld. Bij het hamburger-menu kun je de optie “Download CSV” kiezen.




Figure 2.3: De grondwaterstanden van meetpunt B27G0060 op website <<https://www.grondwatertools.nl/gwsinbeeld/>>{target="_blank"}.

Download dit bestand en sla het op in de **data** map van het project.

💡 Tip

We hebben eerder aangegeven dat je met `source` het hele script kunt uitvoeren. Dat is soms wat omslachtig en wil je alleen een enkele regel uitvoeren. Dat kan door een regel te selecteren en dan op `ctrl+enter` of via menu **Code > Run Selected Line(s)** te kiezen. Dan voer je alleen een enkele regel (of meerdere geselecteerde regels) uit.

De volgende stap is het inladen van dit databestand in de R-omgeving. Dat doen we met de functie `read.csv()` zoals in de onderstaande code is aangegeven. Je ziet ook een pijl staan: `<-`. Dat is de toewijzing aan een variabele. Deze regel betekent letterlijk: maak de variabele `B27G0060001aan` door middel van het uitvoeren van de functie `read.csv("data/B27G0060001_meetreeks.csv")`. Dit is standaard-syntax in R.

```
# read data
B27G0060001 <- read.csv("data/B27G0060001_meetreeks.csv")
```

💡 Tip

Een variabele is een container waarin data wordt opgeslagen (https://www.w3schools.com/r/r_variables.asp). Deze data een enkel getal of tekst zijn, maar ook een hele tabel, matrix of een ander soort object. Het is heel flexibel en de toekenning bepaalt het type.

De naamgeving van een variabele is aan regels gebonden, zie: https://www.w3schools.com/r/r_variables_name.asp. Let op! Een variabele kun je makkelijk overschrijven door deze opnieuw te definiëren.

Wanneer we nu willen weten welke data is ingelezen, kun je de data snel bekijken met de functie `head()`

```
head(B27G0060001)
```

```
      datum.meting
1 1991-12-02;292
2 1992-01-29;314
3 1992-02-28;314
4 1992-03-27;366
5 1992-04-28;341
6 1992-05-27;324
```

Dat ziet er niet goed uit. Als je het csv-bestand opent in een tekst-editor, zoals Notepad/Kladblok of Notepad++ (<https://notepad-plus-plus.org/>) zul je zien dat de data bestaat uit tekst en dat de ; de verschillende velden scheidt (bijvoorbeeld: 1991-12-02;292).

De functie `read.csv()` gaat ervanuit dat een csv uit “comma-separated values” bestaat (https://nl.wikipedia.org/wiki/Kommagescheiden_bestand), vandaar ook de bestandsnaam. De leveranciers van de waterstanden gebruiken echter een puntkomma (;). Gelukkig is de functie flexibel en kun je dit als optie invoeren bij de functie. Als je de code aanpast naar de onderstaande tekst, zal de data wel goed ingelezen worden.

```
# read data
B27G0060001 <- read.csv("data/B27G0060001_meetreeks.csv", sep = ";")
head(B27G0060001)
```

```
      datum meting
1 1991-12-02    292
2 1992-01-29    314
3 1992-02-28    314
4 1992-03-27    366
5 1992-04-28    341
6 1992-05-27    324
```

2.6 Verkennen van de data

Nu de data ingelezen is, kunnen we een aantal zaken te weten komen, zoals de gemiddelde grondwaterstand en bijbehorende standaarddeviatie, en bijvoorbeeld de maximale en minimale standen. Daartoe willen we eigenlijk alleen in de kolom `meting` van ons `data.frame` kijken. Dat doe je door de variable te noemen met daaraan vast een `$`-teken en dan de naam van de kolom: `B27G0060001$meting`

```
# minimale grondwaterstand  
min(B27G0060001$meting)
```

```
[1] 239
```

```
# maximale grondwaterstand  
max(B27G0060001$meting)
```

```
[1] 482
```

```
# gemiddelde grondwaterstand  
mean(B27G0060001$meting)
```

```
[1] 337
```

```
# en de standaarddeviatie  
sd(B27G0060001$meting)
```

```
[1] 57.9
```

De waardes worden niet toegewezen aan variabelen, maar we krijgen wel een beeld van de data. Het is wat omslachtig om dit allemaal apart te berekenen voor een overzicht, dus voor dat doel is de functie `summary()` handiger.

```
# beschrijvende data over de grondwaterstanden  
summary(B27G0060001)
```

datum	meting
Length:93	Min. :239
Class :character	1st Qu.:290
Mode :character	Median :319
	Mean :337
	3rd Qu.:366
	Max. :482

Wanneer we echter willen weten wanneer de hoogste grondwaterstand bereikt werd, dan kan dat door het maximum te zoeken en vervolgens te bepalen bij welke datum dit hoort. In R nemen we dan onze variable B27G0060001 en zoeken dan in de kolom die datum heet. De vierkante haken [] gebruiken we om aan te geven waar we gaan zoeken. Zo kun je zoeken naar de eerste waarde van een kolom of lijst door bijvoorbeeld B27G0060001\$datum[1] in te geven. We moeten daarom weten wat de positie is van de hoogste grondwaterstand in het data.frame. Daarom moeten we in de metingen zoeken naar het maximum. De code B27G0060001\$meting==max(B27G0060001\$meting) geeft aan dat we willen weten wanneer de meting gelijk is aan het maximum. Let op dat je de '==' gebruikt, want dat geeft aan dat je naar *is gelijk aan* wil zoeken. Bij een enkele = maak je alles gelijk aan. De code B27G0060001\$meting==max(B27G0060001\$meting) geeft een waar-onwaar matrix. Door met deze matrix te zoeken in de kolom met datum vinden we de datum waarop de hoogste grondwaterstand waar is.

```
# de eerste datum in de lijst
B27G0060001$datum[1]
```

```
[1] "1991-12-02"
```

```
# de 25e datum in de lijst
B27G0060001$datum[25]
```

```
[1] "1994-01-31"
```

```
# de meting die gelijk is aan het maximum
maximum_stand_waar <- B27G0060001$meting==max(B27G0060001$meting)
# de datum met de maximale grondwaterstand
B27G0060001$datum[maximum_stand_waar]
```

```
[1] "1994-01-31"
```

```
# of als 1 lijn code
B27G0060001$datum[B27G0060001$meting==max(B27G0060001$meting)]
```

```
[1] "1994-01-31"
```


2.7 Zelf aan de slag met een aantal opdrachten

1. Zoek de datum waarop de laagste grondwaterstand werd bereikt.
2. Op welke data was de grondwaterstand lager dan de gemiddelde grondwaterstand?
3. Op welke data was de grondwaterstand lager dan de mediaan van grondwaterstand?

2.8 De eerste grafieken

We gaan nu een eerste grafiek maken met deze gegevens. Hiertoe maken we gebruik van de ggplot2 library. Daarnaast gaan we leren te werken met de syntax die hoort by de zogenaamde tidyverse. Dat doen we door gebruik te maken van een pipe (`|>`). Met dit symbool stuur je als het ware gegevens door. In het onderstaande voorbeeld nemen we de dataset als uitgangspunt en dan pipen we die naar de ggplot-functie, waarbij we aangeven dat de datum op de x-as komt te staan en de metingen op de y-as.


```
# een grafiek met punten
B27G0060001 |>
  ggplot(aes(x=datum, y=meting)) + geom_point()
```



De grafiek is nog niet zo heel mooi en leesbaar. Dat ligt ook aan leesbaarheid van de x-as, dus laten we de labels roteren en er een lijn-geometrie aan toevoegen


```
# een grafiek met punten
B27G0060001 |>
  ggplot(aes(x=datum, y=meting)) +
  geom_point() +
  geom_line() +
  theme(axis.text.x=element_text(angle = -90, hjust = 0))
```

`geom\_line()`: Each group consists of only one observation.
 i Do you need to adjust the group aesthetic?



De labels zijn nu gedraaid, maar nog niet echt leesbaar. Daarnaast worden de waarden op de x-as als nominale data ingelezen, waarbij iedere waarde uniek is, terwijl het om tijd gaat. In dit geval wordt datum als een tekst-variable gezien en niet als datum. Dat moeten we dus aangeven. Daarvoor is een standaard functie beschikbaar `as.POSIXct()`, waarbij het wel belangrijk is om aan te geven dat we de Amsterdamse tijdzone willen gebruiken. Dat kan ook in één code. Daarnaast is het ook behalve om duidelijke as-labels te hebben, dus ook dat voegen we met een stukje code toe (`+ labs(x="Tijd", y="Grondwaterstand (NAP)")`).

```
# een grafiek met punten en lijn
B27G0060001 |>
  mutate(datum = as.POSIXct(datum, tz = "Europe/Amsterdam" )) |>
  ggplot(aes(x=datum, y=meting)) +
  geom_point() +
  geom_line() +
  theme(axis.text.x=element_text(angle = -90, hjust = 0)) +
  labs(x="Tijd", y="Grondwaterstand (NAP)")
```



Deze grafiek is nu beter leesbaar en de verschillende momenten in de tijd worden automatisch gegroepeerd in chronologische volgorde.

We hebben in het voorgaande voorbeeld in de code het datatype van de kolom datum tijdelijk aangepast. Dat kan ook meer blijvend bij het importeren van de data. Dat kan door de volgende code, waarmee we de kolom data muteren van een tekst-kolom naar een kolom met datum/tijd eigenschappen:


```
# tijd in data.frame goed vastleggen
B27G0060001 <- B27G0060001 |>
  mutate(datum = as.POSIXct(datum, tz = "Europe/Amsterdam" ))
```

Het is echter logischer om dit meteen bij de import van het CSV-bestand te doen. Dat kan met de onderstaande code

```
# tijd in data.frame goed vastleggen tijdens de import
B27G0060001 <- read.csv("data/B27G0060001_meetreeks.csv", sep = ";") |>
  mutate(datum = as.POSIXct(datum, tz = "Europe/Amsterdam" ))
```


Laten we de data verder verkennen. De eerste stap is een boxplot voor alle grondwaterstanden te maken

```
# een boxplot maken
B27G0060001 |>
  ggplot(aes(y=meting)) + geom_boxplot() +
  labs(y="Grondwaterstand (NAP)")
```




Het is echter ook mogelijk om de data te groeperen per jaar, om zo inzicht te krijgen in de waterstanden per kalenderjaar. Dit is mogelijk omdat we datum een datum-tijd veld gemaakt hebben. Dankzij het lubridate-package kunnen we makkelijk datum en tijd berekeningen maken. De functie `year()` extraheert het jaar uit een datum. In het onderstaande voorbeeld kun je dus de data groeperen op het jaar en daarna per jaar een boxplot maken.

```
# een boxplot per jaar
B27G0060001 |>
  group_by(jaar = year(datum)) |>
  ggplot(aes(x=jaar, y = meting)) + geom_boxplot(aes(group = jaar)) +
  labs(x="Grondwaterstand (NAP)")
```




Het valt nu op dat er veel variatie zit in de jaren, maar ook dat in sommige jaren de waarden wat dichterbij elkaar liggen. Dit is moeilijk uit een boxplot te halen, maar een *violin plot* geeft soms meer inzicht in hoe de waarden verdeeld zijn.

```
# een violin plot per jaar
B27G0060001 |>
  group_by(jaar = year(datum)) |>
  ggplot(aes(x=jaar, y = meting)) + geom_violin(aes(group = jaar)) +
  labs(x="Grondwaterstand (NAP)")
```



Het is dan ook belangrijk om te weten hoeveel metingen er per jaar zijn. Dat is eenvoudig te visualiseren met behulp van een staafdiagram. Hiertoe moeten we eerst de data weer groeperen per jaar en daarna tellen hoeveel metingen er per jaar zijn. Standaard gaat ggplot uit van het zelf bepalen van de aantallen op basis van de data, maar in dit geval weten we wat de x en de y moet worden en vertellen we dat aan `geom_bar()` door `geom_bar(stat = "identity")` als argument mee te geven, hiermee kun je zelf de x en de y vaststellen.

```
# een bar plot voor aantal metingen per jaar
B27G0060001 |>
  group_by(jaar = year(datum)) |>
  summarise(aantal = n()) |>
  ggplot(aes(x = jaar, y = aantal)) + geom_bar(stat = "identity") +
  labs(x="Jaar", y="Aantal")
```



💡 Tip

Wil je meer weten over het visualiseren van tijdreeksen, staan hier wat handige tips: <https://r-graph-gallery.com/279-plotting-time-series-with-ggplot2.html>

2.9 Zelf aan de slag met een aantal opdrachten

1. Maak de bovenstaande grafieken (boxplot en staafdiagram van aantal metingen per jaar) ook maken voor de maanden. Op die manier kun je zien of er in bepaalde maanden vaker de grondwaterstanden vaker gemeten is.
2. Het is ook mogelijk om een trend te visualiseren in `ggplot()`. Hiertoe gebruik je `geom_smooth()`. Maak een grafiek met de boxplots per jaar, met daaraan toegevoegd de trendlijn
3. Maak een boxplot, waarbij je laat zien wat de grondwaterstanden zijn voor ieder van de vier seizoenen. (<https://www.knmi.nl/over-het-knmi/nieuws/vier-of-zes-seizoenen>)

2.10 Op zoek naar aanvullende data

Het is misschien opgevallen dat de metingen na 2000 ophouden. Voor de meer recente data hebben we blijkbaar een andere bron nodig. Gelukkig kan dat via <https://opendata.munisense>.

[net/nl/](https://net.nl/). Daar vinden we een punt dat zeer vlakbij het meetpunt uit de voorgaande oefening ligt: meetpunt 660721.




Figure 2.4: De website van <https://opendata.munisense.net/nl/>

Wanneer je een CSV-bestand met alle metingen van het meetpunt download en opent in een tekst-editor, zul je zien dat de eerste twee regels geen data bevatten. Die kun je negeren door `skip = 2` aan de opdracht mee te geven.

```
# tijd in data.frame goed vastleggen
gw_660721 <- read.csv("data/660721-water_level_filtered-all.csv", skip = 2)
```

Als je nu vanuit ‘Environment’ de variable bekijkt (klik hier voor een uitleg), zul je zien dat de eerste kolom naar de naam van de rij is gegaan en de laatste kolom leeg lijkt te

zijn.

The screenshot shows the RStudio Environment pane with the variable `gw_660721` selected. The data frame has 4 columns: `timestamp`, `avg_value`, `min_value`, and `max_value`. The first two rows of data are highlighted, showing timestamps and corresponding values.

Deze CSV is blijkbaar niet netjes opgemaakt en wanneer je deze in een teksteditor opent, valt het volgende op: - De kolomkoppen zijn als volgt: `timestamp,avg_value,min_value,max_value` - De regels met data zijn als volgt: `"2015-07-28T00:00:00.000+00:00","2.97","2.97","2.97"`,

```
1 660721-water_level_filtered-all
2
3 timestamp,avg_value,min_value,max_value
4 "2015-07-28T00:00:00.000+00:00","2.97","2.97","2.97"
5 "2015-08-18T00:00:00.000+00:00","2.27","2.27","2.27"
6 "2015-11-16T00:00:00.000+00:00","2.25","2.25","2.25"
```

Figure 2.5: De CSV van 660721 in een tekst editor

Omdat de datavelden eindigen met een komma, wordt er verwacht dat er nog een kolom met data is, maar de kolomkoppen hebben dat niet. Dan leest R de data wel in. De makkelijkste oplossing is nu een komma extra te plaatsen na de kolomkoppen. Dat ziet er dan zo uit.

```
1 660721-water_level_filtered-all
2 ,
3 timestamp,avg_value,min_value,max_value,
4 "2015-07-28T00:00:00.000+00:00","2.97","2.97","2.97",
```

Figure 2.6: De gecorrigeerde CSV van 660721 in een tekst editor

Deze slaan we op als een nieuw bestand, zodat we altijd de originele data behouden. Op deze manier kun je de data inlezen zonder problemen. Het nadeel is wel dat er een extra lege kolom wordt aangemaakt, maar die kun je weer weghalen, door de andere kolommen te selecteren. Daarnaast is het handig om meteen het timestamp veld als datum/tijd in te lezen.

```
# tijd in data.frame goed vastleggen
gw_660721 <- read.csv("data/660721-water_level_filtered-all_edit.csv", skip = 2) |>
  select(timestamp:max_value) |>
  mutate(timestamp = as.POSIXct(timestamp, tz = "Europe/Amsterdam" ))
```

Dit werkt voor een enkel bestand, maar wanneer je veel grondwaterstanden van Munisense moet inlezen, is dat erg bewerkelijk. Je zou ook de data in kunnen lezen en de regel met koppen kunnen overslaan, om daarna de veldnamen te wijzigen. De velden hebben echter geen goede naam, dus om niet de lege kolom te selecteren, selecteren we eerst kolommen 1 tot en met 4, delen daarna namen uit en veranderen het timestamp veld in een datum/tijd veld.

```
# tijd in data.frame goed vastleggen
gw_660721 <- read.csv("data/660721-water_level_filtered-all.csv", skip = 3) |>
  select(1:4) |>
  `colnames<-`(c("timestamp","avg_value","min_value","max_value")) |>
  mutate(timestamp = as.POSIXct(timestamp, tz = "Europe/Amsterdam" ))
```

💡 Tip

De Wet Basisregistratie Ondergrond maakt het mogelijk dat alle publieke gegevens van de Nederlandse ondergrond toegankelijk via één loket. Dat is het BROloket en daar vinden we ook al deze data: <https://www.broloket.nl/ondergrondgegevens>

2.11 Zelf aan de slag met een aantal opdrachten

1. Zoek de datum waarop de laagste grondwaterstand werd bereikt.
2. Op welke data was de grondwaterstand lager dan de gemiddelde grondwaterstand?

3. Op welke data was de grondwaterstand lager dan de mediaan van grondwaterstand?
4. Maak een lijndiagram met de grondwaterstanden van deze dataset, inclusief trendlijn.
5. Maak een staafdiagram met het aantal metingen per jaar.
6. Maak een viool-diagram, zoals eerder gemaakt, maar nu met deze dataset.

2.12 Combineren van datasets

We hebben nu twee datasets met grondwaterstanden van meetpunten die vlak bij elkaar liggen. Laten we deze eens combineren, want op die manier kunnen we voor een langere periode de grondwaterstanden zien.

Om datasets te combineren is praktisch om dezelfde veldnamen te gebruiken. Het commando `colnames` is handig om namen op te vragen, maar ook om ze toe te kennen. Laten we ze eerst eens bekijken:

```
# veldnamen  
colnames(B27G0060001)
```

```
[1] "datum" "meting"
```

```
colnames(gw_660721)
```

```
[1] "timestamp" "avg_value" "min_value" "max_value"
```

Hoewel `gw_660721` vier kolommen heeft, zijn de data in de laatste drie kolommen identiek. Beide datasets hebben een veld met datum en een veld met een grondwaterstand. Als het goed is, valt het ook op dat de eenheid in de ene dataset in meters is, en in de andere in centimeters. Dat moet ook gelijk gemaakt worden. De volgende stappen moeten worden doorlopen - Uniformeren kolomnamen (gebruik maken van `mutate()`) - Uniformeren eenheid getallen (gebruik maken van `mutate()`) - Bron herleidbaar maken (kolom toevoegen met `mutate()`) - Samenvoegen dataset (`rbind()`, [zie hier voor meer voorbeelden](#))

```
# omzetten datasets  
grondwaterstanden <- rbind(  
  B27G0060001 |>  
    mutate(grondwaterstand = meting/100) |>  
    mutate(bron = "grondwatertools") |>  
    select(datum, grondwaterstand, bron),  
  gw_660721 |>  
    mutate(grondwaterstand = avg_value) |>
```

```
mutate(datum = timestamp) |>
mutate(bron = "munisense") |>
select(datum, grondwaterstand, bron)
)
```

Dit kan dus met één samengestelde opdracht.

2.13 Zelf aan de slag met een aantal opdrachten

1. Zoek de datum waarop de laagste grondwaterstand werd bereikt.
2. Op welke data was de grondwaterstand lager dan de gemiddelde grondwaterstand?
3. Op welke data was de grondwaterstand lager dan de mediaan van grondwaterstand?
4. Maak een lijndiagram met de grondwaterstanden van deze dataset, inclusief trendlijn.
5. Maak een staafdiagram met het aantal metingen per jaar.
6. Maak een viool-diagram, zoals eerder gemaakt, maar nu met deze dataset.

Wat valt op aan de datasets? Welke data mis je nog?

2.14 Huiswerk: verwerken in de eigen projecten

Ga op zoek naar de verschillende meetpunten van grondwaterstanden in jouw onderzoeksgebied. Probeer inzicht te krijgen in het verloop van deze grondwaterstanden. Welke rol speelt grondwater in de lokale problemen in jullie onderzoeksgebied?

3 Werkcollege 2: werken met weer- en klimaatdata

3.1 Inleiding

In het vorige werkcollege hebben jullie gewerkt met data van grondwaterstanden uit verschillende bronnen. Daarnaast hebben jullie diverse grafieken gemaakt. Deze week gaan we aan de slag met gegevens over het weer en klimaat.

3.2 Weerdata

Data over het weer wordt door het KNMI als open data aangeboden. Dit is tegenwoordig via <https://dataplatform.knmi.nl/> toegankelijk. De data is toegankelijk via een [API](#). Dit maakt de toegang voor een deel makkelijker, maar er is wel wat code voor nodig. Gelukkig biedt het KNMI ook data aan als eenvoudige downloads: <https://www.knmi.nl/nederland-nu/klimatologie/uurgegevens>. Hierover wordt veel uitgelegd op de website.

We gaan werken met de data uit een bepaald gebied. Laten we eens naar het zuiden van het land kijken en in Limburg op zoek gaan naar data. Op <https://www.knmi.nl/kennis-en-datacentrum/uitleg/automatische-weerstations> staat een kaartje met de locaties van alle weerstations. In Limburg is een weerstation bij Maastricht Airport (380).

Ga naar <https://www.knmi.nl/nederland-nu/klimatologie/uurgegevens> en download de meest recente data uit Maastricht (2021-2030). Dit bestand zal `uurgeg_380_2021-2030.txt` heten.

3.2.1 Project en script aanmaken

Je hebt vorig week geleerd een project aan te maken. Maak een nieuw project aan in een nieuwe map. Deze noemen we nu `Grounded_WC2`.

Maak ook een eerste script aan en geef deze een logische en passende naam. We beginnen weer met het aanroepen van de juiste bibliotheken. Dat zijn deze keer wederom `dplyr` (Wickham, François, et al. 2023), `ggplot` (Wickham 2016) en `lubridate` (Grolemund and Wickham 2011). Daarnaast gaan we nieuwe libraries gebruiken: `tidyr` (Wickham, Vaughan, et al. 2023), `ggpubr` (Kassambara 2023) en `readr` (Wickham et al. 2026).

```
# load libraries
library(dplyr)
library(ggplot2)
library(lubridate)
library(tidyr)
library(ggpubr)
library(readr)

# force non scientific formatting of numbers
options(scipen = 999)
options(digits=3)
```

3.2.2 Data inlezen en de eerste verkenning van de data

Bekijk de data die je gedownload hebt in een tekst-editor. Je zult zien dat de data bestaat uit een hoop uitleg. Dat is heel fijn, omdat je meteen weet wat de data beteken.

```
1 BRON: KONINKLIJK NEDERLANDS METEOROLOGISCH INSTITUUT (KNMI)
2 Opmerking: door stationsverplaatsingen en veranderingen in waarnemethodieken zijn deze
3 tijdreeksen van uurwaarden mogelijk inhomogeen! Dat betekent dat deze reeks van gemeten waarden
4 niet geschikt is voor trendanalyse. Voor studies naar klimaatverandering verwijzen we naar de
5 gehomogeniseerde dagreeksen <http://www.knmi.nl/nederland-nu/klimatologie/daggegevens> of de
6 Centraal Nederland Temperatuur
7 <http://www.knmi.nl/kennis-en-datacentrum/achtergrond/centraal-nederland-temperatuur-cnt>.
8
9 SOURCE: ROYAL NETHERLANDS METEOROLOGICAL INSTITUTE (KNMI)
10 Comment: These time series are inhomogeneous because of station relocations and changes in
11 observation techniques. As a result, these series are not suitable for trend analysis. For climate
12 change studies we refer to the homogenized series of daily data
13 <http://www.knmi.nl/nederland-nu/klimatologie/daggegevens> or the Central Netherlands Temperature
14 <http://www.knmi.nl/kennis-en-datacentrum/achtergrond/centraal-nederland-temperatuur-cnt>.
15
16 YYYYMMDD = datum (YYYY=jaar,MM=maand,DD=dag) / date (YYYY=year,MM=month,DD=day)
17 HH = tijd (HH=uur, UT.12 UT=13 MET, 14 MEZT. Uurvak 05 loopt van 04.00 UT tot 5.00 UT / time
18 (HH uur/hour, UT. 12 UT=13 MET, 14 MEZT. Hourly division 05 runs from 04.00 UT to 5.00 UT
19 DD = Windrichting (in graden) gemiddeld over de laatste 10 minuten van het afgelopen uur
20 (360=noord, 90=oost, 180=ruid, 270=west, 0=windstil, 990=veranderlijk) / Mean wind direction (in
21 degrees) for the 10-minute period preceding the observation time stamp (360=north, 90=east,
22 180=south, 270=west, 0=calm, 990=variable)
23 FH = Windsnelheid (in 0.1 m/s) gemiddeld over het afgelopen uur / Mean wind speed (in 0.1
24 m/s) for the hour preceding the observation time stamp
25 PF = Windsnelheid (in 0.1 m/s) gemiddeld over de laatste 10 minuten van het afgelopen uur /
26 Mean wind speed (in 0.1 m/s) for the 10-minute period preceding the observation time stamp
27 FX = Hoogste windstoot (3 seconde gemiddelde windsnelheid; in 0.1 m/s) gemeten in het
28 afgelopen uur / Maximum wind gust (3 second mean wind speed; in 0.1 m/s) in the preceding hour
29 T = Temperatuur (in 0.1 graden Celsius) op 1.50 m hoogte tijdens de waarneming /
```

Figure 3.1: Data van het KNMI (uurgegevens)

Om de data in te kunnen lezen, plaatsen we het bestand in de `data`-map. Deze had je uiteraard al aangemaakt op basis van de les van vorige week (dat kan met code of middels bestandsbeheer).

Als we de data in proberen te lezen, zal dit niet helemaal goed gaan met het onderstaande commando.

```
```{r}
maastricht_2021_2030 <- read.csv("data/uurgeg_380_2021-2030.txt")
```
```

Je zult het bestand dus even goed moeten bekijken. Dan zul je erachter komen dat je een aantal regels moet overslaan bij het importeren, namelijk 31 regels.

```
maastricht_2021_2030 <- read.csv("data/uurgeg_380_2021-2030.txt", skip = 31)
```

Laten we de data even bekijken. Hieronder staan de eerste 10 regels uit de ingelezen tabel.


| YYYYM-
X..STN | | | | | | | | | | | | | | | | | | | | | | | |
|------------------|--------|-----|----|----|----|-----|----|----|----|-----|----|---|-----|--------|-----|----|------|---|---|---|---|--|--|
| DD | HH | DD | FF | FX | T | T10 | ND | SQ | Q | DRR | H | P | VVN | U | WWX | M | R | S | O | Y | | | |
| 380 | 202101 | 101 | 31 | 20 | 20 | 30 | 21 | NA | 16 | 0 | 0 | 0 | 0 | 100623 | 8 | 96 | NANA | 0 | 0 | 0 | 0 | | |
| 380 | 202102 | 101 | 32 | 20 | 10 | 30 | 20 | NA | 15 | 0 | 0 | 0 | 0 | 100672 | 8 | 96 | NANA | 0 | 0 | 0 | 0 | | |
| 380 | 202103 | 101 | 34 | 10 | 10 | 30 | 19 | NA | 10 | 0 | 0 | 0 | - | 100750 | 8 | 94 | NANA | 0 | 1 | 0 | 0 | | |
| | | | | | | | | | | | | | 1 | | | | | | | | | | |
| 380 | 202104 | 101 | 25 | 10 | 10 | 10 | 17 | NA | 10 | 0 | 0 | 0 | 0 | 100728 | 8 | 95 | NANA | 0 | 0 | 0 | 0 | | |
| 380 | 202105 | 101 | 23 | 10 | 10 | 20 | 15 | NA | 10 | 0 | 0 | 0 | - | 100732 | 8 | 96 | NANA | 0 | 1 | 0 | 0 | | |
| | | | | | | | | | | | | | 1 | | | | | | | | | | |
| 380 | 202106 | 101 | 24 | 10 | 20 | 30 | 14 | 10 | 7 | 0 | 0 | 0 | - | 100736 | 8 | 95 | NANA | 0 | 1 | 0 | 0 | | |
| | | | | | | | | | | | | | 1 | | | | | | | | | | |
| 380 | 202107 | 101 | 22 | 20 | 20 | 30 | 10 | NA | 4 | 0 | 0 | 0 | - | 100841 | 8 | 96 | NANA | 0 | 1 | 0 | 0 | | |
| | | | | | | | | | | | | | 1 | | | | | | | | | | |
| 380 | 202108 | 101 | 21 | 20 | 20 | 40 | 14 | NA | 7 | 0 | 1 | 0 | 0 | 100826 | 8 | 95 | NANA | 0 | 0 | 0 | 0 | | |
| 380 | 202109 | 101 | 22 | 20 | 20 | 30 | 18 | NA | 9 | 2 | 14 | 0 | 0 | 100920 | 8 | 94 | NANA | 0 | 0 | 0 | 0 | | |
| 380 | 202110 | 101 | 22 | 30 | 30 | 40 | 25 | NA | 14 | 0 | 27 | 0 | 0 | 100950 | 8 | 92 | NANA | 0 | 0 | 0 | 0 | | |

Het valt op dat in de kolom RH negatieve waarde voorkomen. In het ingelezen tekstbestand lezen we:

RH = Uursom van de neerslag (in 0.1 mm) (-1 voor <0.05 mm)

Dat betekent dus dat negatieve waardes wel neerslag betekenen, maar minimaal. Wanneer we dit plotten in een boxplot zie je meteen dat er veel lage waardes zijn.

```
maastricht_2021_2030 |>
  ggplot(aes(x=(RH/10))) + geom_boxplot() + labs(x = "Neerslag (mm/dag)")
```



In bovenstaande code is de neerslag getransformeerd naar millimeter per dag, omdat de meeste mensen deze eenheid herkenbaarder zullen vinden dan een neerslag in 0.1 mm.

3.2.2.1 Nu zelf

1. Wat is de gemiddelde neerslag per uur? Welke standaarddeviatie hoort daarbij?
2. Wat is de modale neerslag per uur?
3. Maak een histogram van de neerslag per dag (in mm). Zorg daarbij dat de assen ook een duidelijke benaming krijgen.

Laten we even alle negatieve waardes omzetten naar een waarde die niets betekent, oftewel `NA`. Dat betekent dat we geen waardes hebben voor die momenten. Hiertoe zoeken we alle plekken op waar een -1 staat en vervangen dat voor `NA`:

```
maastricht_2021_2030[maastricht_2021_2030==-1] <- NA
```

3.2.2.2 Nu zelf

Als je `NA` in de data hebt, moet je vaak , `na.rm = TRUE` aan een functie toevoegen. Kijk maar eens in de help van `mean()`.


1. Wat is de gemiddelde neerslag per uur? Welke standaarddeviatie hoort daarbij?

2. Wat is de modale neerslag per uur?
3. Op welke dag viel de meeste neerslag per uur?
4. Maak een nieuwe boxplot van de neerslag. Zie je een verschil met die we eerder hebben gemaakt zonder de -1 te verwijderen?
5. Maak een nieuw histogram van de neerslag per dag (in mm). Zorg daarbij dat de assen ook een duidelijke benaming krijgen.

3.3 Grafieken maken voor de neerslag per dag

De neerslag per uur geeft al veel informatie, maar soms wil je eerder weten wat de hoeveelheden neerslag per dag was. Dat kan vrij eenvoudig door data te groeperen en de som per groep te berekenen. Laten we dat eens doen.

```
maastricht_2021_2030 |>
  group_by(YYYYMMDD) |>
  summarise(neerslagsom = sum((RH/10), na.rm = TRUE)) |>
  ggplot(aes(x=YYYYMMDD, y = neerslagsom)) + geom_bar(stat = "Identity") +
  labs(x = "Datum", y = "Neerslag per dag (mm)")
```



Er val nu meteen op dat er een aantal pieken is, en dat die vrij ver uit elkaar liggen. Dat komt doordat het datatype van het YYYYMMDD-veld een integer is. Dit kun je opzoeken in R door de functie `class()` te gebruiken.

```
class(maastricht_2021_2030$YYYYMMDD)
```


```
[1] "integer"
```

💡 Tip

Wil je weten wat voor gegevenstype een variabele of een bepaalde kolom in een data.frame heeft, gebruik je de functie `class()`.

In het vorige werkcollege heb je al gewerkt met de functies uit de `lubridate`-package (Grolemund and Wickham 2011). Aangezien het veld bestaat uit jaar-maand-dag, kunnen we de functie `ymd()` daarvoor gebruiken en een nieuw veld aan te maken dat we datum noemen.

```
maastricht_2021_2030 |>
  mutate(datum = ymd(YYYYMMDD)) |>
  group_by(datum) |>
  summarise(neerslagsom = sum(RH/10, na.rm = TRUE)) |>
  ggplot(aes(x=datum, y = neerslagsom)) + geom_bar(stat = "Identity") +
  labs(x = "Datum", y = "Neerslag per dag (mm)")
```



Op deze manier wordt de grafiek veel leesbaarder en lijkt ook de variatie beter inzichtelijk te zien. In het bovenstaande voorbeeld hebben we de datum aangepast bij het maken van


de grafiek. Dat is voor een enkele keer handig, maar eigenlijk wat omslachtig. Dit betekent namelijk dat je dit bij iedere bewerking opnieuw moet bepalen, terwijl het handiger is om dit soort dingen in één keer aan te passen, zodat je daarna kunt werken met de bewerkte gegevens. Dat moet je dus eigenlijk meteen doen bij het inlezen van jouw bestand, zodat je daarna alle bewerkingen kunt doen, zonder steeds opnieuw de data te corrigeren. Dat geldt natuurlijk ook voor de neerslag in mm, dus dat passen we ook aan.

```
maastricht_2021_2030 <- read.csv("data/uurgeg_380_2021-2030.txt", skip = 31, colClasses = "integer")
mutate_all(~na_if(., -1)) |>
mutate(datum = ymd(YYYYMMDD)) |>
mutate(neerslag_mm = RH/10)
```

In de bovenstaande code lezen we eerst de CSV in door `maastricht_2021_2030 <- read.csv("data/uurgeg_380_2021-2030.txt", skip = 31, colClasses = "integer")`. In dit voorbeeld zorgen we dat alle kolommen als een integer worden ingelezen, omdat deze data als zodanig wordt aangeleverd door het KNMI. Daarna vervangen we alle -1 waardes voor een NA door `mutate_all(~na_if(., -1))`. De laatste twee regels voegen een datum-veld en veld met de neerslag in millimeter.


Terug naar de grafiek. Als het goed is, is het je opgevallen dat er een enorme piek ergens voor 2022 zichtbaar is. Laten we eens inzoomen op de grafiek in de periode voor 2022, door alleen de data voor 2022 te selecteren:

```
maastricht_2021_2030 |>
  group_by(datum) |>
  filter(YYYYMMDD < 20220000) |>
  summarise(neerslagsom = sum(neerslag_mm, na.rm = TRUE)) |>
  ggplot(aes(x=datum, y = neerslagsom)) + geom_bar(stat = "Identity") +
  labs(x = "Datum", y = "Neerslag per dag (mm)")
```



We zien nu dat dit ergens in juni moet zijn geweest, dus laten we eens wat meer in detail kijken naar de maand juni van 2022. Dat kan met de onderstaande code

```
maastricht_2021_2030 |>
  group_by(datum) |>
  filter(YYYYMMDD >= 20210600 & YYYYMMDD <= 20210700) |>
  summarise(neerslagsom = sum(neerslag_mm, na.rm = TRUE)) |>
  ggplot(aes(x=datum, y = neerslagsom)) + geom_bar(stat = "Identity") +
  labs(x = "Datum", y = "Neerslag per dag (mm)")
```



3.3.1 Weer zelf aan de slag

1. Op welke datum valt deze piek van regen?
2. Maak een staafdiagram van de regen op deze dag, waarbij je per uur aangeeft hoe veel regen er gevallen is. Hoe laat valt de piek?
3. Wat kun je op het nieuws vinden over deze neerslagpiek? Welke gevolgen had dit voor mensen?
4. Welke grondwaterpunten zijn er in de buurt van de meetlocatie te vinden?
5. Maak voor deze meetlocatie een grafiek van de grondwaterstanden. Is er een relatie te vinden tussen neerslag en grondwaterstanden?

3.4 Temperatuur

We hebben nu een aantal grafieken gemaakt voor de neerslag, maar neerslag is niet de enige weerfactor die een bepaalde rol speelt. Er zijn er vele, zoals wind, intensiteit van de zon. Voor het overzicht groeperen we ze hieronder. Ieder heeft andere invloed op de leefomgeving. Dat betreffen:

- Wind (-richting, -snelheid, -stoot)
- Temperatuur (meting, gemiddeld, dauwpunt)
- Zon (duur, straling)

- Neerslag (duur per uur, hoeveelheid)
- Luchtdruk
- Zicht
- Bewolking
- Weersomstandigheden, zoals mist, sneeuw en onweer

Het voert te ver om al deze gegevens te gebruiken in dit werkcollege, maar je zou ze voor verschillende zaken kunnen gebruiken, zoals het bepalen van hittestress of onderzoeken welke invloed mist heeft op de hoeveelheid ongelukken. Dergelijke zaken kun je koppelen aan de inrichting van de leefomgeving en zo tot andere inzichten komen.

Laten we eens verder gaan met de temperatuur in beeld te brengen.


T = Temperatuur (in 0.1 graden Celsius) op 1.50 m hoogte tijdens de waarneming / Temperature (in 0.1 degrees Celsius) at 1.50 m at the time of observation

Ook deze moeten we dus weer aanpassen naar een eenheden in graden en hadden we aan het begin bij importeren natuurlijk moeten bepalen

```
maastricht_2021_2030 <- read.csv("data/uurgeg_380_2021-2030.txt", skip = 31, colClasses = "integer")
mutate_all(~na_if(., -1)) |>
mutate(datum = ymd(YYYYMMDD)) |>
mutate(neerslag_mm = RH/10) |>
mutate(temperatuur_graden = T/10)
```

Laten we eerst eens kijken hoe de gemiddelde temperatuur voor iedere dag in het jaar verloopt.

```
maastricht_2021_2030 |>
group_by(datum) |>
summarise(gem_temp = mean(temperatuur_graden, na.rm = TRUE)) |>
ggplot(aes(x=datum, y = gem_temp)) + geom_line() + labs(x="Datum", y = "Gemiddelde temperatuur")
```



Hierin is duidelijk de trend te zien van de seizoenen. De bovenstaande grafiek geeft echter alleen de gemiddelde temperatuur, maar niet de laagste of de hoogste per dag. Dat is allemaal samen te berekenen en in een grafiek te zetten. Hiertoe moeten we eerst de data samenvatten (`summarise`) en de gemiddeldes, minima en maxima per dag te berekenen. Dan worden er aparte kolommen aangemaakt per waarde. Als we dit echter in een grafiek willen zetten en de kleuren automatisch willen maken, moeten we de kolommen omzetten naar het zogenaamde *longer*-formaat. Het commando `pivot_longer(cols = c(gem_temp, max_temp, min_temp))` zorgt ervoor dat de kolom datum behouden blijft en dat in het veld `name` de titel van de kolommen `gem_temp`, `max_temp` en `min_temp` komt te staan. In het veld `value` komen de waarden te staan. Je hebt in feite de verschillende gegevens getransporteerd en naar een ander formaat omgezet:

```
maastricht_2021_2030 |>
  group_by(datum) |>
  summarise(gem_temp = mean(temperatuur_graden, na.rm = TRUE),
            max_temp = max(temperatuur_graden, na.rm = TRUE),
            min_temp = min(temperatuur_graden, na.rm = TRUE)) |>
  select(datum, gem_temp, min_temp, max_temp) |>
  pivot_longer(cols = c(gem_temp, max_temp, min_temp))
```

```
# A tibble: 6,258 x 3
```

| datum | name | value |
|--------|-------|-------|
| <date> | <chr> | <dbl> |

```

1 2021-01-01 gem_temp 2.04
2 2021-01-01 max_temp 3.5
3 2021-01-01 min_temp 0.4
4 2021-01-02 gem_temp 1.62
5 2021-01-02 max_temp 2.4
6 2021-01-02 min_temp 0
7 2021-01-03 gem_temp 2.14
8 2021-01-03 max_temp 2.6
9 2021-01-03 min_temp 1.5
10 2021-01-04 gem_temp 1.52
# i 6,248 more rows


```

Dit is dan weer goed om te zetten naar een grafiek en de kleur van de lijn zal bepaald worden voor de waarde in de kolom `name`.

```

maastricht_2021_2030 |>
  group_by(datum) |>
  summarise(gem_temp = mean(temperatuur_graden, na.rm = TRUE),
            max_temp = max(temperatuur_graden, na.rm = TRUE),
            min_temp = min(temperatuur_graden, na.rm = TRUE)) |>
  select(datum, gem_temp, min_temp, max_temp) |>
  pivot_longer(cols = c(gem_temp, max_temp, min_temp)) |>
  ggplot(aes(x=datum, y = value)) + geom_line(aes(colour = name)) +
  labs(x="Datum", y="Temperatuur in graden")

```




3.4.1 Nu even zelf nadenken

1. Maak de bovenstaande grafiek voor het jaar 2021.
2. Maak dezelfde grafiek maar dan voor het jaar 2025.
3. Maak dezelfde grafiek maar dan voor het huidige jaar (is weliswaar nog niet afgelopen).
4. Wat valt op wanneer je de verschillende jaren vergelijkt?


We hebben een aantal trends gezien van verschillende jaren. Je zou dit ook kunnen laten zien door de data te groeperen per maand en de daggemiddeldes in een boxplot te zetten:

```
maastricht_2021_2030 |>
  group_by(month(datum)) |>
  ggplot(aes(x=month(datum), y = temperatuur_graden)) + geom_boxplot(aes(group = month(datum)))
  labs(x="Maanden", y = "Temperatuur (graden)")
```



Hier zijn echter de zogenaamde ticks op de x-as niet heel mooi, maar gelukkig kun je dat eenvoudig aanpassen. Dat is wel eenmalig wat typewerk. We gebruiken `scale_x_continuous` omdat de maanden worden omgezet naar een continue schaal in de software. Door de groepering maken het de eenheden echter discreet. Voor de leesbaarheid worden de tekstlabels nog even gedraaid met `+ theme(axis.text.x = element_text(angle = 90, vjust = 0.5, hjust = 1))`.

```
maastricht_2021_2030 |>
  group_by(month(datum)) |>
  ggplot(aes(x=month(datum), y = temperatuur_graden)) + geom_boxplot(aes(group = month(datum))) +
  labs(x="Maanden", y = "Temperatuur (graden)") +
  scale_x_continuous(
    breaks = 1:12,
    labels = c("Januari", "Februari", "Maart", "April", "Mei", "Juni", "Juli", "Augustus", "September", "Oktober", "November", "December")
  ) +
  theme(axis.text.x = element_text(angle = 90, vjust = 0.5, hjust = 1))
```



Door deze grafiek te maken worden de meerjarige trends in de temperatuur duidelijk en begin je een idee te krijgen van het klimaat in onze regio, waarbij de zomers gemiddeld warm zijn en de winters kouder.

3.4.2 Zelf aan de slag


1. Op welke datum is de hoogste temperatuur gemeten in deze periode?
2. Op welke datum is de laagste temperatuur gemeten?
3. In welke jaren vielen de 10 heetste dagen?
4. Maak een grafiek met daarin alleen temperaturen die meer dan 2 standaarddeviaties boven het gemiddelde liggen.

3.5 Grafieken combineren

We hebben hiervoor een grafiek van de neerslag gemaakt en gezien dat in een bepaalde periode in 2021 een extreme hoeveelheid neerslag is geweest. We kunnen nu ook een grafiek maken waarbij en de neerslag en de temperatuur op die dagen te zien is. Het `ggpubr` package biedt mogelijkheden om grafieken te combineren. Hiertoe gebruiken we `ggarrange()`, waarbij de syntax is `ggarrange(grafiek_1, grafiek_2, ncol = 1)`. Op deze manier gebruikt hij twee grafieken en zet ze onder elkaar. Je kunt ze met `nrow = 1` ook naast elkaar zetten. Met deze

functie kun je vele grafieken tegelijkertijd laten zien, waarbij de assen op elkaar afgestemd zijn.

```
ggarrange(  
  maastricht_2021_2030 |>  
    group_by(datum) |>  
    filter(YYYYMMDD >= 20210600 & YYYYMMDD <= 20210715) |>  
    summarise(gem_temp = mean(temperatuur_graden, na.rm = TRUE)) |>  
    ggplot(aes(x=datum, y = gem_temp)) + geom_line() +  
      labs(x="Datum", y = "Gemiddelde temperatuur per dag")  
  ,  
  maastricht_2021_2030 |>  
    group_by(datum) |>  
    filter(YYYYMMDD >= 20210600 & YYYYMMDD <= 20210715) |>  
    summarise(neerslagsom = sum(neerslag_mm, na.rm = TRUE)) |>  
    ggplot(aes(x=datum, y = neerslagsom)) + geom_bar(stat = "Identity") +  
      labs(x="Datum", y = "Neerslagsom per dag")  
  , ncol = 1  
)
```




3.5.1 Zelf aan de slag

1. Maak de bovenstaande grafiek voor januari 2026. Wat valt op?

2. Maak dezelfde grafiek, maar zet nu de neerslag boven en de temperatuur boven.
3. Maak dezelfde grafiek, maar zorg dat de grafieken naast elkaar staan.

Het is ook mogelijk om twee verschillende grafieken te combineren in één grafiek, door bijvoorbeeld eerst een `geom_line()` te maken en daarna met andere data een `geom_bar()` hieraan toe te voegen. Op deze manier krijg je alle data samen in één grafiek. In het onderstaande voorbeeld voegen we een extra y-as toe, ter verduidelijking, met `scale_y_continuous(sec.axis = sec_axis(~.,name = "Neerslag (mm)"))`.

```
maastricht_2021_2030 |>
  group_by(datum) |>
  filter(YYYYMMDD >= 20210600 & YYYYMMDD <= 20210715) |>
  summarise(gem_temp = mean(temperatuur_graden, na.rm = TRUE), neerslagsom = sum(neerslag_mm))
ggplot(aes(x=datum, y = gem_temp)) + geom_line() +
  geom_bar(aes(x=datum, y = neerslagsom), stat = "Identity") +
  scale_y_continuous(sec.axis = sec_axis(~.,name = "Neerslag (mm)")) +
  ylab("Temperatuur (Celsius)")
```




Welke grafiek vind jij duidelijker? Twee losse grafieken of een gecombineerde grafiek met verschillende y-assen? En waarom?

3.6 Klimaat: meerjarige data

We hebben nu vooral data van een enkele weerstation bekeken en de urengegevens gecombineerd tot daggegevens. Het KNMI biedt echter ook veel data aan over hele lange periodes. Het langst-functionerende weerstation is het station in De Bilt. Ga naar <https://www.knmi.nl/nederland-nu/klimatologie/daggegevens> en download daar de data van De Bilt. Het bestand heet `etmgeg_260.zip` pak het zip-bestand uit en plaats `etmgeg_260.txt` in de map met data. Lees dit bestand in en denk daarbij aan de voorgaande opdracht met betrekking tot de datum, de neerslag in mm en de temperatuur in graden. Zorg dus dat je een veld voor `datum` aanmaakt bij inlezen, een voor de neerslag in mm `neerslag_mm` en voor de gemiddelde dagtemperatuur (`temperatuur_gem_graden`). Let goed op hoeveel regels je moet overslaan

Hopelijk is dit geheel zelfstandig gelukt? Laten we eens een grafiek maken van de temperatuur van 1900 tot nu.

```
de_bilt |>
  ggplot(aes(x=datum, y=temperatuur_gem_graden)) + geom_line()
```




3.6.1 Zelf doen:

1. Dit is nog niet heel duidelijk dus voeg zelf even een trendlijn toe, om de trend te zien.

2. Dit is nog steeds niet zo mooi, dus verander de grafiek van een lijndiagram naar een spreidingsdiagram met punten.

Deze trendlijn laat goed zien dat er een opwaartse trend in de gemiddelde dagtemperatuur zit, maar echt een sterke trend zien we niet. Hierbij speelt ook dat de temperatuur in de loop van het jaar in de verschillende seizoenen verandert. Daarom gaan we nu de data groeperen op jaar en dan de gemiddelde temperatuur per jaar berekenen en visualiseren in een grafiek. Dat doen we aldus:

```
de_bilt |>
  group_by(year(datum)) |>
  summarise(gemiddeld_jaar = mean(temperatuur_gem_graden)) |>
  setNames(c("jaar", "gemiddelde_jaartemperatuur")) |>
  ggplot(aes(x=jaar, y=gemiddelde_jaartemperatuur)) + geom_point(aes()) +
  geom_smooth() + labs(x="Jaar", y="Gemiddelde jaartemperatuur")
```



Let hierbij op, want door te groeperen en daarna een gemiddelde te berekenen heeft de kolom met het jaar een nieuwe interne naam gekregen die onhandig is. Daarom helpen we onszelf door de beide kolommen een nieuwe naam te geven met de functie `setNames(c("jaar", "gemiddelde_jaartemperatuur"))`.

De nu gemaakte grafiek laat een veel sterkere verandering van het klimaat zien en dat de gemiddelde jaartemperatuur sinds de jaren '60 zeer sterk is gestegen, iets wat we kennen als klimaatverandering.

3.6.2 En dan weer zelf aan de slag

1. Maak een grafiek van de gemiddelde jaarlijkse neerslag. Zijn daar trends in te zien?
2. Maak een visualisatie van zowel de grafiek met de gemiddelde jaarlijkse temperatuur en die van de neerslag, waarbij deze grafieken boven elkaar staan.
3. Er zijn bepaalde trends zichtbaar. Wat betekent dat voor jouw onderzoeksgebied? Welke aanpassingen zijn nodig in het onderzoeksgebied?

3.7 Historische klimaatdata toevoegen

De metingen in De Bilt worden sinds 1901 goed bijgehouden, maar er bestaan ook oudere metingen, welke ons een goed beeld kunnen geven van de veranderingen van het klimaat over de afgelopen eeuwen. Deze biedt het KNMI ook kosteloos aan via: <https://www.knmi.nl/nederland-nu/klimatologie/daggegevens/antieke-waarnemingen>. Ze bieden diverse data-bronnen aan en we gebruiken nu de langstlopende uit Utrecht: https://cdn.knmi.nl/knmi/map/page/klimatologie/gegevens/daggegevens/antieke_wrn/labrijn_ea.zip. Pak deze zip uit en plaats het bestand `labrijn_ea.dat` in de `data-map`.

Het bestand `labrijn_ea.dat` lijkt een wat exotisch formaat, maar als je deze in een tekst-editor bekijkt, lijkt het gewoon een soort CSV-bestand, maar dan met een andere extensie.

```
1 Monthly, seasonal, and annual means of the airtemperature in tenths
2 of centigrade in De Bilt, Netherlands, 1706.
3 (c) Copyright KNMI De Bilt, Netherlands, 2007.
4 Component observational series:
5 Delft/Rijnsburg (1706-1734), Cwamenburg (1735-1800 & 1811-1848),
6 Haarlem (1801-1810) and Utrecht (1848-1897) reduced to De Bilt
7 and De Bilt (1898-present)
8 Sources for monthly mean airtemperatures:
9 * "Het Klimaat van Nederland gedurende de laatste twee en een halve eeuw",
10 A. Lebrijn, MvV 49, KNMI, 1945. [1735-1900]
11 * "Météorologie Croquis (1678-1734) and his meteorological observations"
12 A. van Engelen & H. Geurts, publ. 168-IV, KNMI, 1985. [1706-1734]
13 * "Het klimaat van het hoofdobservatorium De Bilt in de jaren 1901-1994",
14 Klimatologische Dienst, publ. 150-23, KNMI, 1995. [1901-1994]
15 * "Maandoverzicht van het weer in Nederland",
16 Klimatologische Dienst, Vol. 82-100, KNMI, [1965-heden]
17 Notes:
18 The seasonal and annual mean temperatures have been computed from
19 the monthly means rounded to tenths of centigrades
20
21 Jan Feb Mar Apr May Jun Jul Aug Sep Oct Nov Dec Year Win Spr Sum Aut
22
23 1706 5 32 55 87 146 170 174 173 140 110 44 23 97 96 172 98
24 1707 7 49 47 83 120 168 181 159 149 90 65 19 95 26 83 169 101
25 1708 39 31 59 95 122 146 154 155 159 92 54 4 95 30 92 162 102
26 1709 -51 -3 11 90 116 153 161 162 145 109 70 25 83 -17 73 159 111
27 1710 4 18 56 70 133 150 152 161 147 108 70 55 94 16 86 154 108
28 1711 32 6 50 88 127 168 160 154 162 106 60 34 95 31 92 161 103
29 1712 -1 36 44 88 128 162 167 160 140 109 67 27 94 23 87 163 105
30 1713 -9 56 43 44 116 134 150 166 149 106 52 20 88 25 74 150 102
31 1714 13 44 53 90 108 144 135 143 130 110 63 27 94 28 84 163 101
32 1715 2 42 61 107 121 145 156 148 141 118 79 -12 92 24 96 150 113
33 1716 -57 22 39 102 118 141 144 168 134 94 52 15 83 -16 86 158 94
34 1717 12 14 37 82 107 152 160 165 142 100 52 38 88 14 75 159 98
```


Figure 3.2: De data in het bestand `labrijn_ea.dat`

Het is opvallend dat de data niet door een symbool wordt gescheiden, maar dat er gebruik gemaakt wordt van vaste kolombreedtes. Dat is niet goed in te lezen met `read.csv()`, maar gelukkig zijn er andere tools. De `readr`-library (Wickham et al. 2026) heeft de functie `read_fwf()` die gemaakt is voor het inlezen van fixed-width-files. De titels van de velden staan weer wat onhandig met gewoon inlezen, dat de die eerst skippen en daarna opnieuw aanmaken met `setNames()`

```
labrijn <- read_fwf("data/labrijn_ea.dat", skip = 22) |>
  setNames(c("Jaar", "Jan", "Feb", "Mar", "Apr", "May", "Jun", "Jul", "Aug", "Sep", "Oct", "I
```

Met deze data kunnen we nu eenvoudig verschillende grafieken maken. Laten we beginnen met de gemiddelde jaartemperatuur, met een langjarige trendlijn.


```
labrijn |>
  ggplot(aes(x=Jaar, y=Year_temp/10)) + geom_point() + geom_smooth() +
  labs(y="Gemiddelde temperatuur")
```



Nu wordt nog duidelijker welke enorme gemiddelde opwarming van de aarde op dit moment gaande is en dat die met name sinds het midden van de twintigste eeuw uitermate hard stijgt. We zien ook een grote variatie van jaar tot jaar, maar dat de afgelopen jaren de variatie eigenlijk steeds minder aan het worden is


Het is ook mogelijk om eens te kijken of de temperaturen in de verschillende seizoenen in deze dataset anders toenemen. Daartoe moeten we weer gebruik maken van de `pivot_longer()` optie. Daarnaast zijn alle temperaturen weer in 0.1 graden Celsius, dus ook hier weer omrekenen. Door de kleur te bepalen bij de *aesthetics* bij het aanroepen van `ggplot`, worden de trendlijnen automatisch per seizoen bepaald.

```
labrijn |>
  pivot_longer(cols = c("Win", "Spr", "Sum", "Aut")) |>
  ggplot(aes(x=Jaar, y=value/10, colour=name)) + geom_point() + geom_smooth() +
  labs(y="Gemiddelde temperatuur")
```



Als je de de kleur alleen voor de punten instelt (bij `geom_point()`), zal de algemene trendlijn van alle seizoenen worden bepaald. Dat is in dit geval net geheel logisch, maar kan wel.

```
labrijn |>
  pivot_longer(cols = c("Win", "Spr", "Sum", "Aut")) |>
  ggplot(aes(x=Jaar, y=value/10)) + geom_point(aes(colour=name)) + geom_smooth() +
  labs(y="Gemiddelde temperatuur")
```



Deze laatste trendlijnen in de grafiek is dus minder goed en vertelt ook minder duidelijk een verhaal.

3.7.1 En nu zelf weer aan de slag.

1. Pas legenda van de grafiek met de trendlijnen per seizoen aan en zorg dat deze een duidelijke titel krijgt en dat de namen van de seizoenen uitgeschreven worden. Tip: maak gebruik van `scale_color_discrete()`.
2. Maak dezelfde grafiek maar dan voor de verschillende maanden van het jaar. Welke maanden laten de grootste veranderingen zien?
3. Wat was eigenlijk de warmste maand van de afgelopen eeuwen?
4. Wanneer waren de warmste 10 maanden?
5. Wanneer waren de koudste 10 maanden?

3.8 Project

Denk voor het eigen project na over de volgende vragen.

- Welke invloed heeft het weer op de problemen in mijn onderzoeksgebied?
- Welke invloed heeft het klimaat op de problemen in mijn onderzoeksgebied?
- Welke klimaatsdata heb ik nodig voor mijn onderzoek?

- Er zijn diverse klimaatscenario's (<https://www.knmi.nl/kennis-en-datacentrum/achtergrond/knmi-23-klimaatscenario-s>). Welke invloeden kan je voor de toekomst onderscheiden die invloed hebben op het onderzoeksgebied?

Ga vast aan de slag om de relevante data te verzamelen en maak de benodigde analyses en grafieken.

References

- Grolemund, Garrett, and Hadley Wickham. 2011. “Dates and Times Made Easy with Lubridate.” *Journal of Statistical Software* 40 (3): 125. <https://www.jstatsoft.org/v40/i03/>.
- Kassambara, Alboukadel. 2023. *Ggpubr: 'Ggplot2' Based Publication Ready Plots*. <https://rpkgs.datanovia.com/ggpubr/>.
- Wickham, Hadley. 2016. *Ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York. <http://ggplot2.org>.
- Wickham, Hadley, Romain François, Lionel Henry, Kirill Müller, and Davis Vaughan. 2023. *Dplyr: A Grammar of Data Manipulation*. <https://dplyr.tidyverse.org>.
- Wickham, Hadley, Jim Hester, and Jennifer Bryan. 2026. *Readr: Read Rectangular Text Data*. <https://readr.tidyverse.org>.
- Wickham, Hadley, Davis Vaughan, and Maximilian Girlich. 2023. *Tidyr: Tidy Messy Data*. <https://tidyr.tidyverse.org>.